

MODULE 3 — TP 3

Préparation et Visualisation des Données

Objectifs pédagogiques

- Nettoyer un dataset brut : doublons, types de colonnes, texte mal formaté
- Détecter et traiter les valeurs manquantes (suppression, imputation)
- Détecter les valeurs aberrantes avec la méthode IQR et le boxplot
- Encoder des variables catégorielles (Label Encoding, One-Hot Encoding)
- Normaliser des variables numériques (Min-Max, standardisation z-score)
- Mener une analyse exploratoire (describe, value_counts, corr, groupby)
- Visualiser des données avec Matplotlib (statique) et Plotly (interactif)

M É M O

Résumé de toutes les fonctions

Toutes les fonctions utilisées dans ce TP, classées par étape du prétraitement — à garder sous les yeux pendant le TP.

Nettoyage

`df.duplicated()`

repère les lignes strictement dupliquées

`df.drop_duplicates()`

supprime les doublons

`.str.replace('\u200b', '')`

retire un caractère invisible du texte

`.str.extract(r'(\d+)')`

extraie un nombre depuis du texte

`pd.to_datetime()`

convertit une colonne texte en date

`df.dtypes / .astype()`

vérifie et corrige le type d'une colonne

Valeurs manquantes & aberrantes

```
df.isna().sum()
```

compte les valeurs manquantes par colonne

```
df.dropna(subset=[...])
```

supprime les lignes non reconstituables

```
df.fillna(valeur)
```

impute par une constante ou une statistique

```
df[c].quantile(q)
```

calcule un quantile (ex : Q1, Q3)

```
IQR = Q3 - Q1
```

mesure la dispersion centrale

```
plt.boxplot()
```

visualise les valeurs extrêmes

Encodage & normalisation

```
df[c].nunique()
```

compte les catégories distinctes

```
df[c].map(dict)
```

Label Encoding manuel (variable ordinale)

```
pd.get_dummies()
```

One-Hot Encoding (variable non ordinale)

```
.str.split(',').str[0]
```

extraît la première valeur d'un champ multiple

```
MinMaxScaler().fit_transform()
```

ramène les valeurs entre 0 et 1

```
StandardScaler().fit_transform()
```

centre-réduit (moyenne 0, écart-type 1)

Analyse exploratoire & visualisation

`df.describe()`

statistiques clés des colonnes numériques

`df[c].value_counts()`

compte les occurrences par catégorie

`df.corr()`

matrice de corrélation

`df.groupby(c).agg()`

statistique calculée par groupe

`plt.hist()/.bar()/.scatter()`

histogramme, barres, nuage de points (Matplotlib)

`px.scatter()` / `px.histogram()`

graphiques interactifs (Plotly)

SETUP

Chargement du dataset

Le dataset se charge directement dans Google Colab, sans téléchargement manuel :

```
import pandas as pd
import numpy as np

url = "https://raw.githubusercontent.com/rfordatascience/tidytuesday/main/data/2021/2021-04-20/netflix_titles.csv"
df = pd.read_csv(url)

print("Nombre de lignes :", len(df))
df.head()
```

📌 *Ce dataset contient de vraies valeurs manquantes, des caractères de texte invisibles et une colonne aux unités mélangées — rien n'est simulé.*

SETUP

Description des colonnes

- show_id → identifiant unique (texte)
- type → 'Movie' ou 'TV Show' (catégorielle)
- title → titre de l'œuvre (texte)
- director / cast → réalisateur / acteurs (texte, souvent manquants)
- country → pays de production, parfois plusieurs séparés par une virgule (catégorielle)
- date_added → date d'ajout au catalogue (texte, à convertir)
- release_year → année de sortie (numérique)
- rating → classification d'âge (catégorielle ordinale : G → PG → PG-13 → ... → TV-MA)
- duration → durée : minutes pour les films, nombre de saisons pour les séries (texte mixte, à séparer)
- listed_in → genres associés (catégorielle multiple)

PARTIE A

Nettoyage

Doublons, types, formats

Nettoyage

Question 1 — Le dataset contient-il des lignes strictement dupliquées ? Vérifiez aussi les doublons potentiels sur les colonnes ('title', 'country', 'release_year').

Question 2 — Certains titres ('title') contiennent un caractère invisible (espace de largeur nulle) qui ne s'affiche pas mais empêche les comparaisons exactes. Repérez-en un exemple, puis nettoyez toute la colonne.

Question 3 — Convertissez la colonne 'date_added' (texte) en un vrai type date avec `pd.to_datetime()`.

Question 4 — La colonne 'duration' mélange deux unités selon le type de contenu (minutes pour les films, saisons pour les séries). Séparez-la en deux nouvelles colonnes numériques exploitables : 'duration_minutes' et 'duration_seasons'.

Question 5 — Affichez les types de toutes les colonnes (dtypes) avant et après vos corrections.

PARTIE B

Valeurs manquantes

Détecter, supprimer, imputer

B — VALEURS MANQUANTES

Valeurs manquantes

Question 1 — Comptez le nombre de valeurs manquantes par colonne avec `isna().sum()`.

Question 2 — 'director' a énormément de valeurs manquantes (environ 30%). Les supprimer ferait perdre trop de lignes : remplacez-les par 'Inconnu'.

Question 3 — 'cast' a aussi de nombreuses valeurs manquantes. Remplacez-les par 'Non renseigné'.

Question 4 — 'country' contient des valeurs manquantes non restructurables. Remplacez-les par 'Inconnu'.

Question 5 — 'date_added' et 'rating' n'ont que très peu de valeurs manquantes. Supprimez directement les lignes concernées.

Question 6 — Vérifiez qu'il ne reste plus de valeurs manquantes gênantes.

PARTIE C

Données aberrantes

IQR, boxplot

Données aberrantes

Question 1 — Affichez un boxplot de 'release_year' avec Matplotlib.

Question 2 — Calculez Q1, Q3 et l'IQR de 'release_year' avec quantile().

Question 3 — Déterminez les bornes (règle des $1,5 \times \text{IQR}$) et comptez le nombre de titres considérés comme aberrants (très anciens).

Question 4 — Ces films très anciens sont-ils forcément des erreurs de saisie ? Justifiez avant de décider de les garder ou non.

PARTIE D

Encodage des variables

Label / One-Hot Encoding

Encodage des variables

Question 1 — Combien de valeurs distinctes ont 'type' et 'rating' ? Utilisez `nunique()`.

Question 2 — 'rating' a un ordre logique implicite (classification d'âge : G < PG < PG-13 < ... < TV-MA). Construisez un dictionnaire d'ordre et appliquez un Label Encoding (`map()`) dans 'rating_enc'.

Question 3 — 'type' n'a pas d'ordre naturel (Movie / TV Show). Appliquez un One-Hot Encoding avec `pd.get_dummies()`.

Question 4 — Comparez le nombre de colonnes du DataFrame avant et après cet encodage.

PARTIE E

Normalisation

Min-Max, standardisation

Normalisation

Question 1 — Appliquez un MinMaxScaler sur 'release_year' → colonne 'release_year_norm'.

Question 2 — Appliquez un StandardScaler sur 'duration_minutes' (films uniquement) → colonne 'duration_std'.

Question 3 — Vérifiez les nouvelles échelles avec describe() sur ces deux colonnes.

PARTIE F

Analyse exploratoire (EDA)

describe(), corr(), groupby()

Analyse exploratoire

Question 1 — Affichez `describe()` sur les colonnes numériques. Quelle colonne a le plus grand écart-type ?

Question 2 — Avec `value_counts()`, déterminez la répartition Movie / TV Show, et le pays de production le plus fréquent (indice : utilisez la première valeur de 'country' via `str.split`).

Question 3 — Calculez la corrélation entre 'release_year' et 'duration_minutes'. Les films récents sont-ils plus longs que les films anciens ?

Question 4 — Avec `groupby('type')`, comparez l'année de sortie moyenne des films et des séries.

PARTIE G

Visualisation

Matplotlib et Plotly

Visualisation

Question 1 — Matplotlib : histogramme de 'release_year' (titre et axes nommés).

Question 2 — Matplotlib : diagramme en barres du nombre de titres pour les 10 classifications ('rating') les plus fréquentes.

Question 3 — Matplotlib : nuage de points 'release_year' / 'duration_minutes' (films uniquement).

Question 4 — Plotly : nuage de points interactif équivalent, coloré par 'rating'.

Question 5 — Plotly : histogramme interactif de 'release_year', séparé par 'type' (films vs séries).

Ce qui est attendu

- Un notebook Google Colab avec le dataset nettoyé, encodé et normalisé
- Les réponses aux questions d'analyse (partie F)
- Au minimum 3 graphiques commentés (partie G)
- Chaque transformation justifiée en une phrase dans une cellule de texte

Merci !