

Analyse et Fouille de Données (Data Mining)

1 Définition

L'**analyse de données** est le processus d'exploration, de transformation et d'interprétation des données afin d'en extraire des informations utiles.

La **fouille de données (Data Mining)** est une étape avancée qui consiste à découvrir automatiquement des **modèles cachés**, des **relations**, ou des **tendances** dans de grands volumes de données à l'aide de techniques statistiques et d'intelligence artificielle.

Elle fait partie du processus global appelé :

Processus KDD

KDD (Knowledge Discovery in Databases) comprend :

1. Sélection des données
2. Nettoyage des données
3. Transformation
4. Data Mining (modélisation)
5. Interprétation / Évaluation

2 Étapes de l'Analyse de Données

1. Collecte des données

Sources :

- Bases de données (MySQL, Oracle)
- Fichiers (CSV, Excel)

- Big Data (Hadoop, Spark)
- Web scraping

2. Nettoyage des données

- Suppression des valeurs manquantes
- Correction des erreurs
- Suppression des doublons

3. Analyse exploratoire (EDA)

- Moyenne, médiane
- Visualisations (histogramme, boxplot)
- Corrélation

4. Modélisation

Application d'algorithmes de Machine Learning.

5. Interprétation

- Évaluation des performances
- Validation du modèle

Sélection des données

Définition

La **sélection des données** consiste à choisir uniquement les données utiles pour résoudre le problème.

Objectif

Réduire le volume des données et garder seulement les variables pertinentes.

Exemple

Si vous voulez prédire si un patient aura un AVC, vous sélectionnez :

- Âge
- Tension artérielle
- Diabète
- Cholestérol

Vous ignorez :

- Numéro de téléphone
- Adresse
- Code postal

Actions réalisées

- Choix des colonnes importantes
- Filtrage des lignes (ex: patients > 40 ans)
- Extraction d'une base spécifique

2 Nettoyage des données

Définition

Le **nettoyage** consiste à corriger les erreurs et traiter les données incorrectes.

Problèmes fréquents

- Valeurs manquantes
- Doublons
- Erreurs de saisie

- Valeurs incohérentes

Exemple

Âge	Tension
45	12
?	14
200	13

Problèmes :

- Âge manquant
- Âge = 200 (impossible)

Solutions

- Remplacer par la moyenne
- Supprimer la ligne
- Corriger la valeur

3 Transformation des données

Définition

La **transformation** prépare les données pour les algorithmes.

Pourquoi ?

Les algorithmes fonctionnent mieux avec des données numériques et normalisées.

Exemples

a) Normalisation

Mettre les valeurs entre 0 et 1.

b) Encodage

Transformer texte → nombres

Exemple :

Sexe

Homme

Femme

Devient :

Sex
e

0

1

c) Création de nouvelles variables

Exemple :

Créer **IMC** à partir de poids et taille.

4 Data Mining (Modélisation)

Définition

C'est l'application d'algorithmes pour extraire des modèles.

Objectif

Faire :

- Prédiction
- Classification
- Clustering

Exemple

Si on veut prédire AVC / Non AVC :

On applique :

- Arbre de décision
- Régression logistique
- Réseau neuronal

Le modèle apprend à partir des données.

5 Interprétation / Évaluation

Définition

Évaluer la qualité du modèle et interpréter les résultats.

Questions importantes

- Le modèle est-il précis ?
- Peut-on lui faire confiance ?

Matrice de Confusion (Base de tout)

Avant de comprendre les mesures, il faut connaître :

Matrice de confusion

	Prédit Positif	Prédit Négatif
Réel Positif	TP (True Positive)	FN (False Negative)
Réel Négatif	FP (False Positive)	TN (True Negative)

Signification :

- TP : Malade → prédit malade ✓

- **TN** : Sain → prédit sain ✓
 - **FP** : Sain → prédit malade ✗
 - **FN** : Malade → prédit sain ✗
-

Exemple Numérique

Supposons 100 patients :

- TP = 40
 - TN = 50
 - FP = 5
 - FN = 5
-

2 Accuracy (Exactitude)

✓ Définition

Pourcentage total de prédictions correctes.

Formule

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

Calcul

$$\text{Accuracy} = \frac{40 + 50}{100} = 90\%$$

Interprétation

Le modèle est correct dans 90% des cas.

Problème

Si les données sont déséquilibrées (ex: 95% sains), Accuracy peut être trompeuse.

3 Precision (Précision)

Définition

Parmi les cas prédits positifs, combien sont réellement positifs ?

Formule

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

Calcul

$$\text{Precision} = \frac{40}{40 + 5} = 88.9\%$$

Interprétation

Quand le modèle dit "malade", il a raison 88.9% du temps.

Important en :

- Détection de fraude
- Diagnostic médical

4 Recall (Sensibilité)

Définition

Parmi les vrais positifs, combien ont été détectés ?

Formule

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

Calcul

$$\text{Recall} = \frac{40}{40 + 5} = 88.9\%$$

Interprétation

Le modèle détecte 88.9% des patients malades.

Très important en médecine :

On veut minimiser FN.

5 F1-score

Définition

Moyenne harmonique entre Precision et Recall.

Formule

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Calcul

$$F1 \approx 88.9\%$$

Pourquoi utiliser F1 ?

Quand les données sont déséquilibrées.

Comparaison

Mesure	Quand l'utiliser ?
Accuracy	Données équilibrées
Precision	Quand FP est grave
Recall	Quand FN est grave
F1-score	Quand classes déséquilibrées