

Exercices d'Analyse et Fouille de Données avec Correction

Exercice 1 : Types d'Apprentissage

Énoncé

Classer les problèmes suivants :

Problème	Type d'apprentissage
Détection de spam	?
Segmentation clients	?
Prédiction du prix d'une maison	?
Regroupement d'images similaires	?

Types possibles :

- Supervisé
- Non supervisé

Correction

Problème	Type
Détection de spam	Supervisé
Segmentation clients	Non supervisé
Prédiction du prix d'une maison	Supervisé

Regroupement d'images
similaires

Non
supervisé

Exercice 2 : Classification et Régression

Énoncé

Indiquer si les problèmes suivants sont :

- Classification
- Régression

Cas	Type
Prédire si un patient est malade	
Prédire la température demain	
Reconnaissance des chiffres	
Prédire le salaire d'un employé	

Correction

Cas	Type
Patient malade ou non	Classification
Température	Régression
Reconnaissance des chiffres	Classification
Salaire	Régression

Exercice 3 : Prétraitement des données

Énoncé

Répondre aux questions :

1. Pourquoi le nettoyage des données est important ?
 2. Donner deux exemples de données manquantes.
 3. Donner deux techniques pour traiter les valeurs manquantes.
-

Correction

1. Importance

Le nettoyage permet :

- d'améliorer la qualité des données
 - d'obtenir de meilleurs résultats
-

2. Exemples

- âge vide
 - salaire manquant
-

3. Techniques

- remplacer par la moyenne
 - supprimer les lignes incomplètes
-

Exercice 4 : K-Means

Énoncé

Soient les points :

Point	X	Y
-------	---	---

A	1	1
B	2	1
C	5	4
D	6	5

On choisit :

- $K = 2$

Centroïdes initiaux :

- $C1 = A(1,1)$
- $C2 = C(5,4)$

Travail demandé

Affecter chaque point au cluster le plus proche.

Correction

Cluster 1

Points proches de A :

$A(1,1)$

$B(2,1)$

Cluster 2

Points proches de C :

$C(5,4)$

$D(6,5)$

Nouveaux centroïdes

Cluster 1

$$\begin{aligned} & ((1+2)/2, (1+1)/2) \\ & = (1.5, 1) \end{aligned}$$

Cluster 2

$$\begin{aligned} & ((5+6)/2, (4+5)/2) \\ & = (5.5, 4.5) \end{aligned}$$

Exercice 5 : Matrice de Confusion

Énoncé

Réel / Prédit	Positif	Négatif
Positif	50	10
Négatif	5	35

Calculer :

1. Accuracy
 2. Precision
 3. Recall
-

Correction

Données

- TP = 50
 - FN = 10
 - FP = 5
 - TN = 35
-

Accuracy

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

$$\text{Accuracy} = (50 + 35) / (50 + 35 + 5 + 10)$$

$$\text{Accuracy} = 85 / 100 = 0.85$$

$$\text{Accuracy} = 85\%$$

Precision

$$\text{Precision} = \frac{TP}{TP+FP}$$

$$\text{Precision} = 50 / (50 + 5)$$

$$\text{Precision} = 50 / 55 = 0.909$$

$$\text{Precision} \approx 90.9\%$$

Recall

$$\text{Recall} = \frac{TP}{TP+FN}$$

$$\text{Recall} = 50 / (50 + 10)$$

$$\text{Recall} = 50 / 60 = 0.833$$

$$\text{Recall} \approx 83.3\%$$

Exercice 6 : Arbre de Décision

Énoncé

Répondre :

1. Définir un arbre de décision.
 2. Donner deux avantages.
 3. Donner deux inconvénients.
-

Correction

Définition

Un arbre de décision est un modèle permettant :

- de classer
 - de prendre des décisions sous forme d'arbre
-

Avantages

- facile à comprendre
 - rapide à utiliser
-

Inconvénients

- risque de surapprentissage
 - sensible aux données
-

Exercice 7 : Règles d'Association

Énoncé

Soit la règle :

$\{\text{Pain}\} \rightarrow \{\text{Lait}\}$

Sachant que :

- 40 clients ont acheté Pain et Lait
- 50 clients ont acheté Pain
- 100 clients au total

Calculer :

1. Support
 2. Confiance
-

Correction

Support

$\text{Support} = \frac{\text{Nombre}(\text{Pain} \cap \text{Lait})}{\text{Nombre}(\text{Pain} \cup \text{Lait})}$
 $\text{Support} = \frac{\text{Nombre}(\text{Pain} \cap \text{Lait})}{\text{Nombre}(\text{Pain}) + \text{Nombre}(\text{Lait}) - \text{Nombre}(\text{Pain} \cap \text{Lait})}$

Support = 40 / 100

Support = 0.4 = 40%

Confiance

$\text{Confiance} = \frac{\text{Nombre}(\text{Pain} \cap \text{Lait})}{\text{Nombre}(\text{Pain})}$
 $\text{Confiance} = \frac{\text{Nombre}(\text{Pain} \cap \text{Lait})}{\text{Nombre}(\text{Pain})}$

Confiance = 40 / 50

Confiance = 0.8 = 80%

Exercice 8 : Programmation Python

Énoncé

Créer un programme Python permettant :

1. de lire un fichier CSV
 2. d'afficher :
 - les premières lignes
 - les valeurs manquantes
 - la moyenne d'une colonne
-

Correction

```
import pandas as pd
```

```
data = pd.read_csv("etudiants.csv")
```

```
print(data.head())
```

```
print(data.isnull().sum())
```

```
print(data["note"].mean())
```

Exercice 9 : Vrai/Faux

Question	Réponse
K-Means est supervisé	Faux
La régression prédit des nombres	Vrai
La classification utilise des classes	Vrai
Le clustering nécessite des labels	Faux
Apriori utilise les règles d'association	Vrai

Exercice 10 : QCM

1. Quel algorithme est utilisé pour le clustering ?

- A. CNN
- B. K-Means
- C. Dijkstra
- D. BFS

Correction

Réponse : B

2. Quel algorithme est supervisé ?

- A. K-Means
- B. Apriori
- C. Régression linéaire
- D. Clustering

Correction

Réponse : C

3. Accuracy mesure :

- A. vitesse
- B. précision globale
- C. stockage
- D. mémoire

Correction

Réponse : B