

série complète de révision en Analyse et Fouille de Données (Data Mining)

Partie 1 : Concepts de base

Exercice 1

Définir :

- Analyse de données
 - Fouille de données
 - Big Data
 - Data Warehouse
-

Exercice 2

Quelle est la différence entre :

- Données structurées / non structurées
 - Analyse descriptive / prédictive / prescriptive
-

Exercice 3

Donner les étapes du processus KDD (Knowledge Discovery in Databases)

◆ Partie 2 : Prétraitement des données

Exercice 4

Pourquoi le prétraitement est-il important ?

Exercice 5

Donner les techniques suivantes :

- Nettoyage des données
 - Normalisation
 - Discrétisation
-

Exercice 6

On donne les valeurs :

10,20,30,40,50 10, 20, 30, 40, 50 10,20,30,40,50

👉 Appliquer :

1. Normalisation Min-Max
 2. Standardisation (Z-score)
-

◆ Partie 3 : Statistiques de base

Exercice 7

Calculer :

- Moyenne
- Médiane
- Variance
- Écart-type

Pour : 2,4,6,8,10, 4, 6, 8, 10, 2,4,6,8,10

Exercice 8

Expliquer :

- Corrélation
 - Covariance
-

◆ Partie 4 : Classification

Exercice 9

Définir :

- Classification supervisée
 - Classe / attribut
 - Modèle d'apprentissage
-

Exercice 10

Expliquer les algorithmes suivants :

- Decision Tree
 - K-Nearest Neighbors
 - Naive Bayes
-

Exercice 11

Donner les étapes de construction d'un arbre de décision

◆ Partie 5 : Clustering

Exercice 12

Définir :

- Clustering
 - Distance euclidienne
-

Exercice 13

Expliquer l'algorithme :

- K-Means
-

Exercice 14

On donne les points :
(1,1), (2,2), (8,8), (9,9)

👉 Appliquer K-Means avec $K=2$

◆ Partie 6 : Règles d'association

Exercice 15

Définir :

- Support
 - Confiance
 - Lift
-

Exercice 16

Expliquer l'algorithme :

- Apriori
-

Exercice 17

On donne les transactions :

ID	Articles
----	----------

T1	A, B
----	------

T2	A, C
----	------

T3	A, B, C
----	---------

👉 Calculer :

- Support de (A)
 - Confiance de $A \rightarrow B$
-

◆ Partie 7 : Évaluation des modèles

Exercice 18

Définir :

- Accuracy
 - Precision
 - Recall
 - F1-score
-

Exercice 19

On donne :

	Prédit Oui	Prédit Non
Réel Oui	40	10
Réel Non	5	45

👉 Calculer :

- Accuracy
 - Precision
 - Recall
-

◆ Partie 8 : Réduction de dimension

Exercice 20

Définir :

- Réduction de dimension
 - Sélection de caractéristiques
-

Exercice 21

Expliquer :

- Principal Component Analysis
-

◆ **Partie 9 : Applications**

Exercice 22

Donner des applications de la fouille de données :

- Détection de fraude
 - Systèmes de recommandation
 - Médecine (ex : prédiction des AVC)
-

◆ **Partie 10 : Niveau avancé**

Exercice 23

Comparer :

- Classification vs Clustering
-

Exercice 24

Expliquer le problème de surapprentissage (Overfitting)