

série de révision complète en fouille de données **(Data Mining)**

Partie 1 : Concepts fondamentaux

Exercice 1

Définir :

- Fouille de données
 - Apprentissage automatique
 - Base de données
 - Entrepôt de données (Data Warehouse)
-

Exercice 2

Expliquer la différence entre :

- Données structurées / semi-structurées / non structurées
 - OLTP vs OLAP
-

Exercice 3

Donner les étapes du processus KDD :

1. Sélection
 2. Prétraitement
 3. Transformation
 4. Fouille de données
 5. Interprétation
-

Partie 2 : Prétraitement des données

Exercice 4

Pourquoi les données doivent-elles être nettoyées ?

Exercice 5

Expliquer :

- Valeurs manquantes
 - Bruit
 - Données aberrantes (outliers)
-

Exercice 6

Soit les données :

5,10,15,20,255,10,15,20,25

Appliquer :

1. Normalisation Min-Max
 2. Standardisation (Z-score)
-

Partie 3 : Statistiques

Exercice 7

Calculer :

- Moyenne
- Médiane
- Variance
- Écart-type

Pour : 1,2,3,4,51,2,3,4,5

Exercice 8

Expliquer :

- Corrélation
 - Covariance
-

Partie 4 : Classification

Exercice 9

Définir :

- Apprentissage supervisé
 - Ensemble d'apprentissage
 - Classe
-

Exercice 10

Expliquer les algorithmes :

- Decision Tree
 - K-Nearest Neighbors
 - Naive Bayes
-

Exercice 11

Construire un arbre de décision simple à partir d'un petit jeu de données

Partie 5 : Clustering

Exercice 12

Définir :

- Clustering
 - Distance euclidienne
-

Exercice 13

Expliquer :

- K-Means
-

Exercice 14

Soit les points :

(2,2), (3,3), (8,8), (9,9)

Appliquer K-Means avec $K = 2$

Partie 6 : Règles d'association

Exercice 15

Définir :

- Support
 - Confiance
 - Lift
-

Exercice 16

Expliquer :

- Apriori
-

Exercice 17

Transactions :

ID	Articles
----	----------

T1	A, B
----	------

T2	B, C
----	------

T3	A, B, C
----	---------

Calculer :

- Support(A)
 - Confiance($A \rightarrow B$)
-

Partie 7 : Évaluation des modèles

Exercice 18

Définir :

- Accuracy
 - Precision
 - Recall
 - F1-score
-

Exercice 19

Matrice de confusion :

	Prédit Oui	Prédit Non
Réel Oui	30	10
Réel Non	5	55

Calculer :

- Accuracy
 - Precision
 - Recall
-

Partie 8 : Réduction de dimension

Exercice 20

Définir :

- Réduction de dimension
 - Sélection de variables
-

Exercice 21

Expliquer :

- Principal Component Analysis
-

Partie 9 : Applications

Exercice 22

Donner des applications :

- Détection de fraude
 - Médecine (ex : AVC)
 - Recommandation de produits
-

Partie 10 : Niveau avancé

Exercice 23

Comparer :

- Classification vs Clustering
-

Exercice 24

Expliquer :

- Overfitting
 - Underfitting
-