

TP COMPLET : Classification et Évaluation d'un Modèle

Thème

Prédiction d'une tumeur **bénigne ou maligne** à partir de données médicales.

Dataset : **Breast Cancer Wisconsin**

Source : UCI Machine Learning Repository

OBJECTIFS DU TP

À la fin de ce TP, l'étudiant sera capable de :

- Charger un dataset réel
 - Explorer les données
 - Séparer Train/Test
 - Créer un modèle de classification
 - Construire une matrice de confusion
 - Calculer Accuracy, Precision, Recall, F1-score
 - Interpréter les résultats
-

PRÉREQUIS

Installer les bibliothèques :

```
pip install pandas scikit-learn matplotlib seaborn
```

PARTIE 1 : Chargement du Dataset

Étape 1 : Importation

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.datasets import load_breast_cancer
```

Étape 2 : Charger les données

```
data = load_breast_cancer()

X = data.data
y = data.target

print("Nombre d'échantillons :", X.shape[0])
print("Nombre de variables :", X.shape[1])
```

Explication

- 569 patients
 - 30 variables médicales
 - y = 0 (maligne), 1 (bénigne)
-

PARTIE 2 : Exploration des données

```
df = pd.DataFrame(X, columns=data.feature_names)
df["target"] = y

print(df.head())
print(df.info())
print(df.describe())
```

Objectif

Comprendre :

- Nombre de colonnes
 - Type des variables
 - Statistiques (moyenne, min, max)
-

PARTIE 3 : Séparation Train/Test

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42
)
```

Explication

- 70% pour entraîner
 - 30% pour tester
 - Test sert à évaluer la performance
-

PARTIE 4 : Création du Modèle

Nous utilisons **Régression Logistique**.

```
from sklearn.linear_model import LogisticRegression

model = LogisticRegression(max_iter=5000)
model.fit(X_train, y_train)
```

Explication

Le modèle apprend la relation entre variables médicales et type de tumeur.

PARTIE 5 : Prédiction

```
y_pred = model.predict(X_test)
```

Le modèle prédit maintenant les classes.

PARTIE 6 : Matrice de Confusion

```
from sklearn.metrics import confusion_matrix
```

```
cm = confusion_matrix(y_test, y_pred)  
print(cm)
```