

TP – Prédiction du prix des maisons (Regression)

Objectif :

- Charger un dataset
 - Explorer les données
 - Séparer les données en **train/test**
 - Entraîner un modèle de **régression linéaire**
 - Évaluer les performances
-

1 Importer les bibliothèques

```
import pandas as pd
import numpy as np
from sklearn.datasets import load_boston # dataset classique pour régression
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt
```

⚠ Note : `load_boston` est déprécié dans les versions récentes de scikit-learn, mais pour un TP simple c'est pratique. Sinon on peut utiliser un dataset CSV.

2 Charger le dataset

```
# Charger les données
boston = load_boston()
X = pd.DataFrame(boston.data, columns=boston.feature_names)
y = pd.Series(boston.target)

print("Dimensions de X :", X.shape)
print("Aperçu des données :\n", X.head())
```

3 Séparer les données en train/test

```
X_train, X_test, y_train, y_test = train_test_split(  
    X, y, test_size=0.2, random_state=42  
)
```

```
print("Taille du train :", X_train.shape)  
print("Taille du test :", X_test.shape)
```

4 Créer et entraîner le modèle

```
# Créer le modèle de régression linéaire  
model = LinearRegression()
```

```
# Entraîner le modèle  
model.fit(X_train, y_train)
```

5 Prédiction et évaluation

```
# Prédiction sur les données de test  
y_pred = model.predict(X_test)
```

```
# Évaluer la performance  
mse = mean_squared_error(y_test, y_pred)  
r2 = r2_score(y_test, y_pred)
```

```
print("Mean Squared Error (MSE) :", mse)  
print("R² Score :", r2)
```

6 Visualisation des résultats

```
plt.scatter(y_test, y_pred)  
plt.xlabel("Prix réel")  
plt.ylabel("Prix prédit")  
plt.title("Régression linéaire : réel vs prédit")  
plt.plot([min(y_test), max(y_test)], [min(y_test), max(y_test)], 'r--') # ligne y=x  
plt.show()
```