

Partie 1 : Concepts de base

Exercice 1

- **Analyse de données** : processus d'inspection, nettoyage et interprétation des données pour extraire des informations utiles.
 - **Fouille de données** : extraction automatique de connaissances à partir de grandes bases de données.
 - **Big Data** : données massives caractérisées par volume, variété et vitesse.
 - **Data Warehouse** : entrepôt centralisé pour stocker et analyser les données historiques.
-

Exercice 2

- **Structurées** : données organisées (tables, SQL)
 - **Non structurées** : texte, images, vidéos
 - **Analyse descriptive** : que s'est-il passé ?
 - **Analyse prédictive** : que va-t-il se passer ?
 - **Analyse prescriptive** : que faut-il faire ?
-

Exercice 3 (KDD)

1. Sélection des données
 2. Nettoyage (prétraitement)
 3. Transformation
 4. Fouille de données
 5. Interprétation / évaluation
-

Partie 2 : Prétraitement

Exercice 4

Le prétraitement est important pour :

- Éliminer le bruit
- Gérer les données manquantes
- Améliorer la qualité des modèles

Exercice 5

- **Nettoyage** : corriger erreurs et valeurs manquantes
 - **Normalisation** : mise à l'échelle des données
 - **Discrétisation** : transformer données continues en classes
-

Exercice 6

Données : 10, 20, 30, 40, 50

Min = 10, Max = 50

Normalisation Min-Max :

$$X' = \frac{X - \text{Min}}{\text{Max} - \text{Min}} = \frac{X - 10}{50 - 10}$$

Résultat :

- $10 \rightarrow 0$
 - $20 \rightarrow 0.25$
 - $30 \rightarrow 0.5$
 - $40 \rightarrow 0.75$
 - $50 \rightarrow 1$
-

Standardisation (Z-score)

Moyenne = 30

Écart-type ≈ 14.14

$$Z = \frac{X - \text{Moyenne}}{\text{Écart-type}} = \frac{X - 30}{14.14}$$

Résultats approximatifs :

- $10 \rightarrow -1.41$
 - $20 \rightarrow -0.71$
 - $30 \rightarrow 0$
 - $40 \rightarrow 0.71$
 - $50 \rightarrow 1.41$
-

Partie 3 : Statistiques

Exercice 7

Données : 2, 4, 6, 8, 10

- Moyenne = 6
 - Médiane = 6
 - Variance = 8
 - Écart-type ≈ 2.83
-

Exercice 8

- **Covariance** : mesure la variation conjointe de deux variables
 - **Corrélation** : covariance normalisée (entre -1 et 1)
-

Partie 4 : Classification

Exercice 9

- **Classification supervisée** : apprentissage avec données étiquetées
 - **Classe** : catégorie cible
 - **Attribut** : caractéristique d'entrée
 - **Modèle** : fonction apprise pour prédire
-

Exercice 10

- Decision Tree : structure en arbre basée sur des règles
 - K-Nearest Neighbors : classe selon les voisins proches
 - Naive Bayes : basé sur les probabilités
-

Exercice 11

Étapes :

1. Choisir l'attribut racine (gain d'information)
2. Diviser les données
3. Répéter récursivement

4. Arrêter selon un critère (profondeur, pureté)
-

Partie 5 : Clustering

Exercice 12

- **Clustering** : regrouper données similaires
- **Distance euclidienne** :

$$d = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

Exercice 13

- K-Means :
 1. Choisir K centres
 2. Assigner points au centre le plus proche
 3. Recalculer centres
 4. Répéter jusqu'à convergence
-

Exercice 14

Points : (1,1), (2,2), (8,8), (9,9)

K = 2

Clusters finaux :

- Cluster 1 : (1,1), (2,2)
- Cluster 2 : (8,8), (9,9)

Centres :

- (1.5, 1.5)
 - (8.5, 8.5)
-

Partie 6 : Règles d'association

Exercice 15

- **Support** : fréquence d'un item
 - **Confiance** : probabilité conditionnelle
 - **Lift** : dépendance entre items
-

Exercice 16

- Apriori :
 - Génère itemsets fréquents
 - Élimine ceux non fréquents
 - Génère règles
-

Exercice 17

Transactions :

- T1 : A, B
- T2 : A, C
- T3 : A, B, C

Total = 3

- $\text{Support}(A) = 3/3 = 1$
- $\text{Support}(A,B) = 2/3$

$\text{Confiance}(A \rightarrow B) = \frac{\text{Support}(A,B)}{\text{Support}(A)} = \frac{2/3}{1} = 2/3$

Partie 7 : Évaluation

Exercice 18

- **Accuracy** = $(TP+TN)/\text{Total}$
 - **Precision** = $TP/(TP+FP)$
 - **Recall** = $TP/(TP+FN)$
 - **F1-score** = moyenne harmonique
-

Exercice 19

Données :

- TP = 40

- $FN = 10$
- $FP = 5$
- $TN = 45$

Total = 100

- Accuracy = $(40+45)/100 = 0.85$
 - Precision = $40/(40+5) = 0.89$
 - Recall = $40/(40+10) = 0.8$
-

Partie 8 : Réduction de dimension

Exercice 20

- **Réduction de dimension** : diminuer le nombre de variables
 - **Sélection de caractéristiques** : choisir les plus importantes
-

Exercice 21

- Principal Component Analysis :
 - Transforme variables en composantes principales
 - Réduit dimension tout en gardant l'information
-

Partie 9 : Applications

Exercice 22

- Détection de fraude bancaire
 - Systèmes de recommandation (Netflix, Amazon)
 - Médecine : prédiction des AVC
-

Partie 10 : Niveau avancé

Exercice 23

Classification	Clustering
Supervisée	Non supervisée
Données étiquetées	Données non étiquetées
Prédiction	Regroupement

Exercice 24

Overfitting (surapprentissage) :

- Le modèle apprend trop bien les données d'entraînement
- Mauvaise généralisation

Solutions :

- Plus de données
 - Régularisation
 - Validation croisée
-